

PROYECTO 1 ETAPA 2

Reporte del Análisis de datos para la detección de noticias falsas

INTELIGENCIA DE NEGOCIO
Equipo 7

Anderson Arévalo Mendoza, 202014997
Juan José Hurtado Cantin, 202224472
Nicolás Pérez Ramos, 202221292

FECHA: FEBRERO, 2025

TABLA DE CONTENIDO

Contexto del problema	3
Introducción	3
Automatización del proceso de preparación de datos y documentación.....	3
Acceso por medio de API	4
Aplicación y proceso de negocio	4
Elaboración de la aplicación	4
Relación con el grupo de estadística.....	5
Tareas realizadas	5

Contexto del problema

La proliferación de noticias falsas (**fake news**) en plataformas digitales representa un desafío crítico para las organizaciones que buscan mantener la integridad de la información y proteger a sus usuarios de la desinformación. Estas noticias engañosas, diseñadas para manipular la opinión pública o generar clics masivos, pueden tener consecuencias negativas como la propagación de rumores, pérdida de credibilidad y desconfianza entre los usuarios. Ante este contexto, surge la necesidad de implementar sistemas automáticos de detección de fake news que permitan identificar y filtrar contenido fraudulento de manera eficiente, garantizando así la difusión de información verídica y protegiendo la reputación de la plataforma.

Introducción

El modelo que se definió en primer lugar fue de Random Forest Classifier, ya que fue un modelo del que obtuvimos unas muy buenas métricas a la hora de evaluar su rendimiento respecto a los datos de entrenamiento y los de prueba. Sin embargo, a medida que se actualizan los datos, cambian los patrones y las características de la información que se recopila, el modelo pierde precisión y las predicciones que realiza no son del todo acertadas. Es por esto que se necesita de un reentrenamiento del modelo, para que se adapte a la nueva información y pueda realizar predicciones correctas y útiles para quien haga uso del modelo.

Para lograr solucionar el inconveniente que se presenta por la nueva información recibida, se decidió implementar un reentrenamiento completo del modelo, utilizando información antigua y nueva. De esta manera se puede garantizar que el modelo utilice todos los datos para realizar predicciones más acertadas, a pesar de significar un mayor costo computacional, también implica que el modelo siga funcionando correctamente a pesar de las nuevas tendencias en los datos.

Automatización del proceso de preparación de datos y documentación

Para garantizar la eficiencia del modelo se implementó un proceso automático de preparación de datos, de manera que se redujo la intervención manual y se aseguró de que el tratamiento de los datos sea consistente. Este proceso se integra en un pipeline de preprocesamiento, en el cual se aplican algunas transformaciones como la eliminación de caracteres especiales, puntuación, stopwords y el reemplazo de números. Estandarizando la entrada del texto al modelo para que este mejore su capacidad de predicción y su precisión. Además, después de esta transformación se integra la información presente en el título y en la descripción.

También se realiza un entrenamiento del modelo Random Forest Classifier con los datos procesados y se realiza la respectiva evaluación del modelo tomando en cuenta métricas

como la precisión, el accuracy, el recall y el F1-score, además de un reporte de clasificación y la matriz de confusión para ilustrar de manera más clara los resultados del modelo.

Se desarrolla una API haciendo uso de fastapi para exponer el modelo y permitir predicciones en tiempo real. Tomando en cuenta los endpoints definidos, los cuales se documentaron como “/predecir/” para clasificar nuevos datos y “/reentrenar/” para actualizar el modelo con los nuevos datos etiquetados.

Acceso por medio de API

El acceso al modelo analítico se realiza mediante una API REST desarrollada con FastAPI, que permite la interacción entre el modelo y la aplicación web de manera eficiente y estructurada. Esta API cuenta con dos endpoints principales: uno para la predicción de noticias, el cual recibe un archivo CSV con datos de entrada y retorna una lista de predicciones junto con su probabilidad; y otro para el reentrenamiento del modelo, que permite actualizar el modelo con nuevas instancias etiquetadas, devolviendo métricas como precisión, recall y F1-score. Ambos endpoints aceptan y devuelven información en formato JSON, lo cual facilita la integración con aplicaciones frontend como la desarrollada en React. Este enfoque asegura que la funcionalidad del modelo pueda ser accedida de forma remota, escalable y segura, promoviendo su reutilización en otros sistemas de la organización.

Aplicación y proceso de negocio

La aplicación desarrollada tiene como objetivo apoyar a organizaciones en la detección automática de noticias falsas, facilitando la toma de decisiones informadas en tiempo real. Esta solución se integra al proceso de negocio como una herramienta de validación previa a la publicación o difusión de contenido, permitiendo cargar archivos con noticias y recibir una predicción junto con la probabilidad de que una noticia sea falsa o verdadera. De esta forma, el modelo analítico no solo agiliza el proceso de verificación, sino que también contribuye a reducir la desinformación, proteger la reputación de la entidad y generar mayor confianza en el público. Además, al permitir el reentrenamiento del modelo desde la interfaz, se garantiza su adaptación continua a nuevas formas de manipulación informativa.

Elaboración de la aplicación

La elaboración de la aplicación se llevó a cabo utilizando React para el desarrollo del frontend, ofreciendo una interfaz intuitiva y minimalista que permite a los usuarios subir archivos CSV con noticias para su análisis. En el backend se implementó una API REST con FastAPI, la cual conecta con el modelo entrenado previamente usando técnicas de procesamiento de lenguaje natural (NLP) y un clasificador SVM. La aplicación está estructurada para facilitar dos funciones clave: realizar predicciones sobre nuevas noticias y permitir el reentrenamiento del modelo con datos etiquetados, manteniendo así su capacidad de adaptación. Durante el

desarrollo se priorizó la simplicidad en la interacción, el modularidad del código y el cumplimiento de los requisitos funcionales del negocio, asegurando una solución práctica, escalable y útil para combatir la desinformación.

Relación con el grupo de estadística

Se realizó un trabajo en conjunto con el grupo de estadística, quienes nos brindaron algunas recomendaciones para mejorar la calidad del modelo y del proyecto en general. Una de las recomendaciones más importantes fue realizar un preprocesamiento del texto, esto con el fin de obtener un modelo más robusto y reducir el ruido en los datos, siguiendo esta recomendación implementamos un pipeline con el que es posible limpiar y estandarizar los textos que hay en los datos, de manera que la información que se le entrega al modelo sea homogénea y el modelo pueda aprender únicamente la información relevante sin que se vea afectado por información que no es importante para realizar la predicción.

Algunas de las acciones que se realizan con el pipeline son la eliminación de caracteres especiales, conversión del texto a minúscula, eliminar puntuación, reemplazar números y eliminar stopwords. Esta limpieza de los datos se realiza tanto para el título como para el texto de las noticias, además se combina la información del título y del texto como una única representación con el fin de que se tome en cuenta toda la información para realizar las predicciones.

Tareas realizadas

Nos dividimos el trabajo de modo que todos los integrantes del grupo pudieran aportar a la realización del mismo.

Anderson fue el encargado de realizar el primer endpoint, plantear su reentrenamiento del modelo y realizar gran parte del código que se requiere para el funcionamiento del backend. De igual forma, desarrollo la preparación para las pruebas de las técnicas de reentrenamiento. Explicación del API y la unión de los 2 endpoints

Juan José fue el encargado de realizar el segundo endpoint, plantear su reentrenamiento del modelo y realizar el documento entregable.

Nicolás fue el encargado de diseñar la interfaz, realizar la conexión con el API, realizar el análisis de resultados, plantear su reentrenamiento del modelo y mostrar el funcionamiento de la página web.

A pesar de la distribución de tareas, se realizó una colaboración para algunas tareas, de manera que, si alguien tenía dudas con respecto a la realización de esta, se pedía colaboración para que los demás integrantes del grupo pudieran ayudar con el cumplimiento del objetivo.

Se considera un trabajo equitativo entre los integrantes por lo que todos obtienen un puntaje de 33.3% es decir los 100 puntos se reparten en partes iguales